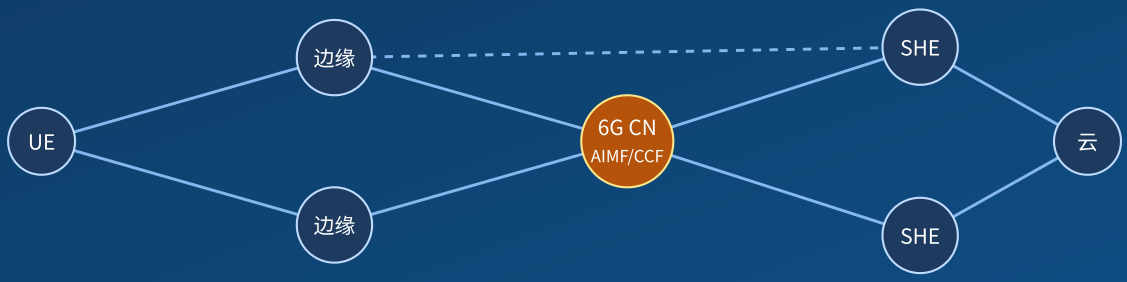
技术分析报告 · 6G NETWORK FOR AI · 标准对齐

广域 KV Cache CDN 场景下的时序侧信道防护构想与 3GPP 6G 标准对齐分析

基于 TR 23.801-01 V0.10.0（6G 系统架构研究）、TR 33.801-01 V0.7.0（6G 安全研究）与 TR 22.870 V20.0.0（6G 用例与业务需求）



分析对象：附件《防KV Cache侧信道攻击.md》中的"五层体验无损联合防御体系"

标准基线：3GPP TR 23.801-01 V0.10.0（2026-10，Release 20，研究阶段草案）

报告日期：2026 年 11 月 10 日

说明：TR 23.801-01 / 33.801-01 均为 Release 20 研究阶段草案，文中引用的"原则 / 临时结论（Interim Agreement）"仍可能变化；Release 21 才是首个 6G 规范性版本（Stage-2 冻结计划为 2028 年 6 月）。

目 录

0 执行摘要 3

1 分析输入、方法与标准现状 4

2 对构想与附件问题的理解 5

3 最新 6G 标准基线解读（与构想相关部分） 6

3.1 架构假设与架构需求 6

3.2 KI#19：6G 网络为 AI 提供推理服务 6

3.3 KI#22：6G 计算支持 7

3.4 KI#21 / KI#4 / KI#5 / KI#7 / KI#18 8

3.5 6G 安全研究（TR 33.801-01） 9

3.6 6G 业务需求（TR 22.870） 9

4 场景对齐：把 KV Cache CDN 映射进 6G 架构 11

5 用 3GPP 语言重构威胁模型（含标准引入的新泄露面） 12

6 基于 3GPP 已有方案的五层防御增强 14

7 建议的整体架构与关键流程 17

8 标准化切入路径与时间窗口 19

9 构想中不合适 / 需修正之处（独立章节） 20

10 结论与下一步 23

附录 参考资料与条款索引 24

0　执行摘要

一句话结论

你的"广域 KV Cache CDN + 分级侧信道防护"构想**与 6G 方向高度契合，但它目前在 3GPP 中是"空白区"**：最新 TR 23.801-01 V0.10.0、TR 33.801-01 V0.7.0、TR 22.870 V20.0.0 三份文档中均**没有出现 "KV cache" 或 "side channel" 字样**（全文检索确认）。最佳的落脚点是 **KI#19 第 4 条（6G CN 向应用提供 AI 推理服务）中的 AISF "AI context correlation and caching management"**，并以 **KI#22（SHE 计算站点、有状态计算上下文迁移）**承载广域分发；安全侧则在 SA3 尚无对应关键问题，存在**提出新 Key Issue 的窗口**。

0	0	3 处	12 项
三份 TR 中 "KV cache" 出现次数	三份 TR 中 "side channel" 出现次数	标准现有方案会**放大**侧信道（见第 5 章）	构想需修正之处（见第 9 章）

核心发现

1. **场景契合点充足**。TR 22.870 已有 6G 网络提供 AI 推理（PR 6.10.6-1~5）、第三方模型托管于 6G 网络并做长文档分析（6.34）、网络知识用于 RAG 提示增强（PR 6.13.6-1）、分布式 AI 计算（6.24）等用例，这些都是 KV 前缀复用收益最大的负载。
2. **架构挂点明确**。TR 23.801-01 第 6.19.4 节定义了 AIMF（管理）/ AIOF（执行）/ AIRF（仓库）/ AISF（导引，含"AI 上下文关联与缓存管理"），并已形成临时结论（7.1.19.2）；第 6.22 节提出 SHE、CCF/CMF，以及**"有状态计算服务需要计算上下文缓存（computing context cache）并先建立迁移链路"**——这几乎就是 KV Cache 跨站迁移的标准语言。
3. **标准自身引入了新的侧信道放大器**（这是你构想可以显著增值的地方）：① Solution #22.9 Variant B 提议向 AF 暴露 TTFT、ms/token 等计算指标；② Solution 变体 #19.4 Mechanism 2 由 AIOF 向 UE 下发"负载大小→推理处理时间"映射；③ AIMF 授权后可把**所选 AIOF 的地址**返回给消费者——若选择是缓存感知的，地址本身就泄露命中状态；④ 计算资源用量（如消耗 token 数）用于计费，若命中折扣计费则计费记录泄露命中。
4. **五层防御均可找到 3GPP "宿主"**：分级→AI 服务上下文 + 运营商策略（PCF）+ 签约数据；盲化→租户/安全域隔离的命名空间 + 与签约绑定的密钥；时序对齐→KI#5 动态 QoS 与"首个推理结果最大时延"参数；探测检测→SA3 安全区 #7（安全监测 / 响应框架，明确允许"重定向恶意流量"）；影子计算→SHE 内实现。
5. **构想中有若干点不宜原样进标准**（第 9 章）：最关键的三条是——*雪崩哈希并不能阻止整前缀猜测*（真正起作用的是"按安全域分盐 = 命名空间隔离"）；*对齐到 ~100 ms 只能隐藏"本地命中 vs 远端命中"，隐藏不了"命中 vs 未命中"*；*向已认证签约用户静默返回伪造数据*与 3GPP 的 KPI 保障、可信 AI、合法监听和消费者保护要求冲突，建议改为"隔离实例 + 诱饵前缀（canary）"。

建议的定位（一句话版本，可用于提案标题）

> "Support of secure, operator-controlled reuse of AI inference context (e.g. KV cache) across Computing Sites for network AI inference service, with protection against inference-context timing side channels."
> （面向网络 AI 推理服务、跨计算站点、运营商可控的推理上下文复用及其时序侧信道防护）

1　分析输入、方法与标准现状

1.1　分析输入

文档	版本 / 日期	本报告使用方式
附件《防KV Cache侧信道攻击.md》	用户提供	问题陈述、五层防御、预期效果
3GPP TR 23.801-01《Study on Architecture for 6G System; Stage 2》	**V0.10.0（2026-10）**，归档目录中最新版本（23801-01-0a0）	主基线：架构假设/需求、24 个 Key Issue、方案变体、第 7 章临时结论。逐节解析全部 27 个分册
3GPP TR 33.801-01《Study on Security for the 6G System》	V0.7.0（2026-10）	TR 23.801-01 §4.2 明确"应考虑"的安全需求来源
3GPP TR 22.870《Study on 6G Use Cases and Service Requirements》	V20.0.0（2026-03）	TR 23.801-01 KI#22 指定的业务需求起点；3GPP 官方称其为 Rel-21 规范工作的 Stage-1 锚点
学术文献（NDSS 2025 PROMPTPEEK、SafeKV 等）	2025–2026	佐证攻击可行性与防御代价，用于校准附件中的定量主张

1.2　方法

1. 将 TR 23.801-01 全部分册转成文本，按 Key Issue → Solution → Interim Agreement 三级梳理；以关键词（KV cache、prefix、side channel、cach、context、token、TTFT、isolation、privacy 等）全文检索定位相关条款。
2. 把附件中的每个组件与每层防御映射到 3GPP 网元/功能、参数与流程，按"契合度"打分（高 中 低）。
3. 反向检查：标准现有方案是否会**制造或放大**侧信道；构想中哪些内容与标准原则冲突或不属于 3GPP 范围。

1.3 标准现状与时间窗口

3GPP 决定以两个 Release 完成 6G：Release 20 做研究，Release 21 做首个规范性版本。根据 3GPP 官网，2026 年 6 月 TSG#112 全会确定的 Rel-21 时间表为：Stage-1 冻结 2027 年 3 月；**Stage-2 冻结 2028 年 6 月**（2028 年 3 月达到 80% 检查点）；Stage-3 冻结 2028 年 12 月；ASN.1/OpenAPI 冻结 2029 年 3 月。[3GPP Release 21]

> **对你的含义**
>
> TR 23.801-01 仍是 V0.x 草案，KI#19 第 4 条的架构选项尚未收敛（"Which architecture option(s) will be down-selected is FFS"），AIMF/AISF/AIOF 的功能划分也是 FFS。**这正是把"推理上下文复用 + 侧信道防护"写进方案描述与临时结论的最佳时机**；进入 Rel-21 规范阶段后，新增功能的门槛会显著提高。

2 对构想与附件问题的理解

2.1 构想：KV Cache 作为可广域分发的"内容"

在端-边-云协同推理中，Transformer 的 prefill 阶段为提示前缀生成 Key/Value 张量。若多个请求共享相同前缀（系统提示词、公共 RAG 文档、工具说明、多轮对话历史），已算好的 KV 块就可被复用，从而省掉 prefill 计算、显著降低首 token 时延（TTFT）。你的构想是把这种复用从单机/单集群扩展到**广域多节点**：KV 块像 CDN 内容一样在边缘与中心之间被索引、拉取、迁移和淘汰。

2.2 附件识别的核心问题

问题	附件描述	本报告的理解与校准
Hit/Miss 时间差成为窃密信道	命中约 10–100 ms，未命中 5000 ms+；攻击者逐 token 微调提示并测量时延，恢复他人私有前缀	已有学术实证：NDSS 2025 论文展示了基于 KV 共享的提示泄露攻击；SafeKV 汇总的文献报告部分场景成功率接近或超过 89%，代价约 10^2 次请求/token [SafeKV]
6G 放大攻击精度	确定性网络微秒级低抖动、算力感知路由使路径差异显性化、MEC 多租户密度高	方向成立，但需改用标准内已有的表述（QoS 监测、网络/计算指标暴露、计算站点选择），见 §5 与 §9
现有防御陷入死局	严格隔离毁掉复用；全局延迟注入伤体验且可被统计滤除；限流挡不住分布式慢速探测	与文献一致：SafeKV 测得按用户隔离会使 Llama-2-70B 的 TTFT 增加 8.3%–38.9%；填充/抖动需逼近未命中分布的高分位才能对抗统计检验

2.3　附件的五层防御（原文要点）

层	机制	要点
L1	无感自动语义分级	基于"租户熵"（跨租户共享度）与 Radix Tree 拓扑特征，自动划分 L0 公共 ~ L3 绝密，无需用户打标签
L2	前缀盲化与防碰撞	"语义哈希 + SHA-256 强雪崩"生成路由 Salt，微调 1 个 token 即令 Salt 剧变，破坏"前缀→时延"映射梯度
L3	体验无损时序对齐	命中时延对齐到"跨节点拉取时间"（~100 ms）而非重算时间，抹平边缘节点缓存状态差异
L4	探测检测与静默反制	监控前缀树"深节点高频微分叉"；识别后不封禁、不告警，静默路由至蜜罐推理实例，让攻击者收集伪造数据
L5	不可观测化执行	对 <1% 的 L3 绝密请求启用"影子计算"，命中与未命中走相同计算路径与耗时

预期效果：L0 复用率 ⩾95%，合法用户 TTFT 增加 ⩽5%，攻击者 30 天内无法以 >80% 置信度区分 Hit/Miss。

3　最新 6G 标准基线解读（与构想相关部分）

3.1　架构假设与架构需求（TR 23.801-01 § 4）

- 以 5GC 的 SBA 为起点；保持 RAN/CN 功能划分；6G RAN 只连 6G CN；原生支持地面与非地面网络。
- **"shall"**：支持漫游；支持多厂商互通接口。**"should"**：云原生、可持续与能效、鲁棒与韧性；引入新特性时尽量减少 NF 间依赖。
- **必须考虑合法监听（TS 33.126）；应考虑 TR 33.801-01 的安全需求。**

> **对构想的约束**
>
> 任何 KV 复用方案都要回答三个"标准必答题"：①漫游/跨运营商时如何处理；②接口是否多厂商可互通（意味着标准只定义信令与信息模型，KV 内部格式留给实现）；③合法监听与安全需求如何满足。

3.2　KI#19：6G 网络为 AI——向应用提供 AI 推理服务（最核心挂点）

KI#19 第 4 条："研究 6G CN 是否以及如何向应用（AF 或 UE 内应用）提供 AI 服务（AI 推理与 AI 训练）"。方案变体 #19.4 提出四类功能：

功能	标准中的职责（摘要）	与 KV Cache CDN 的关系

AIMF 管理功能	接收并授权 UE/AF 的 AI 服务请求；按请求、资源状态、网络状态**发现并选择 AIOF**；确定 QoS/KPI 配置；从策略功能获取 AI 服务策略；维护 AIOF 上报的负载、资源状态、处理时延	KV 感知的节点选择、共享范围策略下发的天然位置
AIOF 执行功能	执行推理；收集数据；向消费者发送结果；上报性能；执行 AIMF 下发的配置与策略；（推理）与 UE 动态交换任务 ID、负载大小、期望 KPI 以调整时延预算	即"KV Cache 节点 + 推理引擎"；时序对齐与影子计算在此执行
AIRF 仓库功能	存储训练好的模型、预配置模型以及**AI 推理结果**；与 AIMF 交互确定模型	可扩展为"可复用推理上下文"的索引/登记
AISF 导引功能	按任务输入选择一个或多个 AIOF 实例；**"AI context correlation and caching management"**；聚合多模型输出。流程中写明"AISF caches AI context for the ongoing service session"	**最接近 KV Cache 管理的现成条文**；且其与 AIMF/AIOF 的功能划分仍为 FFS

其他关键原文要点：

- **AI 推理会话上下文（AI Inference Session context）**：每个已授权推理请求维护一个持久上下文，关联请求者身份、所选 AIOF 实例、模型 ID/版本，**跨 UE 移动保留**，并可维护"资源绑定"；"其他信息元素为 FFS，留待规范阶段定义"。→ 可写入"上下文复用范围 / 安全等级"等新 IE。
- **KPI 保障的 6 种机制**：①AI 资源与通信资源协同（AIMF 推导上行、推理处理、*首个下行推理结果最大时延*等 QoS 要求）；②在路交换参数动态调整时延预算（AIOF→UE 下发"负载大小与推理处理时间的映射"）；③UE-网络拆分/分布式推理；④Agentic Trust Proxy 基于无状态令牌执行"信任条件配额"；⑤运行时协同自适应；⑥预测性自适应。
- **授权**：AIMF 或 NEF 依据请求信息、UDM 签约数据（是否允许 AI 服务、允许的 AI 服务类型）与预配置策略授权；每个 AI 服务独立授权。
- **服务连续性**：AIMF 可依据网络状态、处理时延、负载、可用性或策略触发 AIOF 资源重绑定（dynamic resource rebinding）。
- **推理结果的详细参数属于应用层载荷，3GPP 不定义**（"application layer payload and might be 3GPP-unspecified"）。

> **已形成的临时结论（§7.1.19.2）**
>
> 6G CN 支持面向应用的网络 AI 服务：AI 训练/推理管理功能、训练/推理执行功能、AI 仓库功能；支持授权（每个 AI 服务请求独立授权）；支持消费者请求推理服务、推理数据收集与传输、向消费者提供推理结果、双方可终止服务。*架构选项的收敛仍为 FFS。*

3.3　KI#22：6G 计算支持（广域分发的承载面）

- **临时结论（§7.1.22.1）**：Service Hosting Environment（SHE）是**运营商域内、完全由运营商控制**的环境；应用层流量**仅经 6G UPF** 进入 SHE；SA2 不规定应用组件的打包、存储、安装、实例化与生命周期管理；引入 **Computing Coordination Function（CCF）**协调通信与计算并与计算托管环境中的控制器交互。

- **计算站点选择**：CMF 感知内外部计算资源状态与能力，SMF 与 CMF 协同选择 UPF 与计算节点（Solution #22.2）。
- **计算服务连续性**（Solution #22.2 变体 A/C/D/E/F/J）：引入 Computing Service Continuity Policy；明确**"对有状态计算服务，需要计算上下文缓存（computing context cache），须先建立迁移链路以在计算会话切换前完成上下文迁移"**；迁移链路可在源/目标节点间直连或**经 6G UPF**；Make-before-Break 模式下有 context-assisted、progress-assisted、state-preserving 三种续算方式。
- **计算信息暴露**（Solution #22.9）：Variant A 采用**抽象化暴露**（不对外暴露基础设施细节，抽象为运营商定义的服务等级）；Variant B 提议 CMF 向 AF 暴露三级指标，其中业务级包括 **Time to First Token、每 token 执行时延（ms/token）**；Variant E 明确"不暴露计算专属测量"。Solution #22.15：SHE 控制器只向 CCCE 报告抽象的"策略符合状态"，计算专属测量不外露。
- **网络指标暴露**（Solution #22.10）：向授权 AF 暴露 N3/N9/N6 与 E2E 时延监测、预测性路径时延等。
- **计费**：计算资源用量信息（如"消耗的 token 数"、CPU/GPU 数）可作为上报与门限。
- **漫游**：计算漫游将在规范阶段以 TS 23.548 的 HR-SBO 流程为基线。

3.4　KI#21 / KI#4 / KI#5 / KI#7 / KI#18（支撑性能力）

KI	已形成的原则 / 方案要点	可借用之处
KI#21 数据框架	临时结论：数据控制/传输/处理/存储/暴露/登记发现 6 大功能；存储支持跨请求复用、避免重复采集；按元数据治理复用，"可限制只被特定 NF 或 NF 类型复用"；基于运营商策略的访问控制；订户许可执行；处理功能可做匿名化/假名化；**消费者访问数据框架的接口为非漫游接口**	"按元数据治理的复用范围限制"思想可直接移植为 KV 共享范围控制；但数据框架面向"6G 系统数据"，不宜直接承载用户 KV（见 §9）
KI#4 用户面	xUPF 包含"业务特定功能"（如 PDU Set 处理、MoQ 中继）；UP 路径按 RAN-xUPF-应用服务器之间的路径性能（时延、抖动）选择；Solution #4.10 提出可调用的增值业务用户面（VAS-UP）	"首包释放时刻量化"可作为 xUPF/VAS-UP 的业务特定功能；路径性能测量用于 KV 拉取路径选择
KI#5 QoS	QoS Flow 为最细粒度；6QI；支持应用随时间变化的 QoS 需求（在网络授权范围内）；UE-UPF、UPF-DN 用户面协作层（暴露网络状态、接收突发信息）；QoS 监测增强（包/PDU Set 粒度时延）	把"对齐目标时延"表达为授权 QoS 参数；但协作层与监测也是攻击者的"高精度尺子"（§5）
KI#7 网络暴露	临时结论：服务 API 式暴露、调用授权；"信息暴露基于运营商策略/SLA"；隐私保护、用户许可、数据匿名化；暴露"以运营商可控方式"进行；支持带意图的调用请求	在暴露框架中对时延类指标做粒度/噪声/频率控制
KI#18 AI for 6G	临时结论：运营商通过 6G CN 内执行与 OAM 控制网络对 AI 能力的使用；支持 NF 级 AI 能力激活/去激活；按业务或 UE/AF 级授权意图请求	KV 共享开关、等级策略由运营商可控（满足"operator controllability"）

3.5　6G 安全研究（TR 33.801-01 V0.7.0）

当前安全区包括：安全架构、RAN、UE-CN、核心网/互联/漫游、签约认证授权、**网络暴露安全（#6）**、**面向安全监测的数据采集（#7）**、**UE AI Agent 安全与隐私（#8）**、**数据框架安全（#9）**、感知安全、NTN 安全。与本构想直接相关的条文：

- **KI#7.2 安全相关数据**：威胁中明确"使用合法凭证（如被盗凭证）的攻击不会产生失败交互，安全事件中不可见"；"缺乏关联信息时，跨多个 NF 的攻击无法检测"。潜在需求：支持采集异常事件数据、支持检测使用合法凭证的攻击、支持关联。——*KV 探测恰恰是"合法凭证 + 合法 API + 分布式"的攻击。*
- **KI#7.3 安全响应框架**：临时结论 NOTE 写明将复用已定义的响应机制来"**修复检测到的威胁和/或重定向检测到的恶意流量、异常行为和/或可疑 API 调用**"。——为 L4"重定向"提供了直接依据。
- **安全区 #6**：KI#6.1（第三方 AI Agent 作为 CAPIF API 调用者）、KI#6.3（来自核心网的 Agentic 暴露安全）、KI#6.4（基于意图的暴露）——均聚焦认证、授权、接口保护。
- **安全区 #8** 仅覆盖 UE AI Agent（KI#19 第 1、2 条），KI#18 相关为 FFS；**KI#19 第 4 条（网络 AI 推理服务）目前没有对应的 SA3 关键问题**。

> **空白点**
>
> SA3 现有关键问题全部围绕"认证/授权/机密性/完整性/重放"，**没有任何关于推理服务时序侧信道、跨租户推理上下文泄露的关键问题**。这是本构想最有价值的标准化切入口之一。

3.6　6G 业务需求（TR 22.870 V20.0.0）

需求编号	内容（摘要）	与构想的关系
PR 6.10.6-1/2/3	6G 网络能向 UE 提供 AI 服务（如推理）；支持协商并保障时延、推理精度等服务性能	KV 复用是满足推理时延 KPI 的关键手段
PR 6.10.6-4/5	为分布式 AI 推理调度网络与 SHE 计算资源，并保障其性能	广域 KV 分发即分布式推理的资源调度
6.34 / PR 6.34.6-1~3	第三方公司在 6G 网络安装 AI 模型并租用算力；用户做大批量专业文档分析；授权卸载、选择计算资源、高优先级处理	典型长上下文、共享文档前缀场景；同时是多租户场景
PR 6.13.6-1	向授权第三方 AI Agent 暴露网络信息用于提示增强（RAG）	"网络知识"作为公共前缀（L0）的天然来源
PR 6.2.6-4	按 UE 移动与性能要求在不同位置的 SHE 计算资源间高效迁移计算任务	KV 跨站迁移的需求依据
PR 5.5.4.2-2	**按不同业务安全需求支持细粒度安全隔离**	分级隔离（L0–L3）的直接需求依据
PR 5.5.4.2-4/5/6	识别潜在安全威胁；生成安全增强策略；向网元下发并执行安全响应	L4 探测检测与响应

PR 5.5.7.3-2	为接入 6G 服务（通信、感知、**AI 推理**）的 UE 提供用户隐私、身份保护	侧信道泄露提示内容即违反隐私保护
PR 5.9.2.2-4	6G 系统数据全生命周期（采集、传输、处理、**存储**、暴露）安全与隐私保护	KV 块的存储/迁移/淘汰需全周期保护
PR 6.39.6-1	可在 AI 服务请求中接收 AI 相关服务需求（如精度、时延）（负责任 AI 用例）	与"返回伪造数据"的反制策略存在张力（§9）

4　场景对齐：把 KV Cache CDN 映射进 6G 架构

4.1　建议的标准化表述

不要把它叫做"KV Cache CDN"进标准——3GPP 的风格是功能与信息模型中立。建议使用**"可复用 AI 推理上下文（Reusable AI Inference Context, RAIC）"**，并在 NOTE 中举例"e.g. KV cache of transformer-based models"。这样既契合 AISF 的"AI context caching management"，又不绑定具体模型结构。

4.2　组件映射表

构想组件	6G 对应实体 / 条款	契合度	说明
边缘/区域 KV 节点（存 + 算）	AIOF 部署于 SHE 中的 Computing Site（§ 6.19.4 选项 1/4 "AIOF 可由用户面类 NF 支持"；§ 7.1.22.1）	高	SHE 由运营商完全控制，流量经 6G UPF 进入，便于集中执行策略
全局 KV 索引 / 目录	AISF（AI context correlation and caching management）+ AIRF（存储推理结果）	高	AIMF/AISF/AIOF 划分仍为 FFS，可在划分中明确"上下文索引在 AISF，块存储在 AIOF"
KV 感知调度（选哪个节点）	AIMF 发现与选择 AIOF；CMF/CCF 计算站点选择；SMF 的 UPF 选择	高	新增选择输入："上下文可用性"——需防止其成为泄露源（§ 5）
跨节点 KV 拉取 / 迁移	KI#22 有状态计算的"computing context cache"迁移链路（直连或经 6G UPF）；AIMF 资源重绑定	高	可直接引用 Make-before-Break + state-preserving 续算
租户/安全等级	AI 推理会话上下文（IE 为 FFS）+ UDM 签约数据（允许的 AI 服务类型）+ PCF 策略（AI 资源使用、模型/AIOF 选择策略）	高	新增 IE："Context Reuse Scope"、"Context Sensitivity Level"
公共前缀来源（系统提示、公共 RAG）	AIRF 预配置模型/上下文；PR 6.13.6-1 网络知识	中	"预置公共上下文"可由运营商或 AF 显式登记为 L0
时延对齐	KPI 机制 1/2（首个下行推理结果最大时延）；KI#5 动态 QoS；xUPF 业务特定功能	中	标准可定义"目标释放时延/量化粒度"参数，算法留给实现
探测检测与响应	TR 33.801-01 KI#7.2/7.3；PR 5.5.4.2-4~6；AIMF 资源重绑定	中	3GPP 只定义数据采集与响应机制，检测算法在 3GPP 外

影子计算 / 恒定时间执行	SHE 内实现；属"应用组件"范畴	低	SA2 不规定应用组件 LCM，只能以策略标识（如"恒定时延执行要求"）触发
跨运营商 / 第三方 CDN 共享	漫游：计算漫游以 HR-SBO 为基线；数据框架接口非漫游	低	首期建议限定在单 PLMN 的 SHE 内（§9）

4.3 典型场景（与 TR 22.870 用例对应）

场景	对应用例	共享内容与安全等级
S1 运营商网络知识增强的 GenAI	6.13 RAG / PR 6.13.6-1	网络知识前缀、公共系统提示 → L0 全网共享
S2 第三方模型托管 + 企业文档分析	6.34 / PR 6.34.6-x	企业私有 RAG 文档、私有系统提示 → L2/L3，仅租户内共享
S3 移动中的多轮 AI 助理	6.10 / PR 6.2.6-4	单用户对话历史 → 会话内复用，随 UE 移动跨站迁移
S4 能源感知的分布式推理	6.24 / PR 6.24.6-2	热门公共前缀在多站复制，按能源与负载调度
S5 医疗/金融等高敏推理	6.30 智慧医疗 / PR 5.5.7.3-2	L3：禁止跨租户复用，启用恒定时延执行

5 用 3GPP 语言重构威胁模型（含标准引入的新泄露面）

5.1 资产、攻击者与信道

要素	描述
资产	其他租户/用户的提示前缀（私有系统提示、企业 RAG 文档、对话历史、个人数据）；以及"某前缀被某租户使用过"这一事实本身（元数据隐私）
攻击者 A1	已签约 UE 上的恶意应用（经 AIMF 授权、合法使用推理服务）
攻击者 A2	经 NEF/暴露框架接入的恶意或被攻破 AF（可订阅时延/计算指标）
攻击者 A3	由大量 SIM/UE 组成的分布式慢速探测群（规避单账号限流）
不在范围	SHE 内部特权攻击者、物理侧信道（功耗/电磁）——属于平台安全与 TEE 范畴

5.2 五类泄露信道

#	信道	机理	相关标准内容
C1	TTFT 时序	附件主信道：命中/未命中的首结果时延差	KPI 机制 1"首个推理结果"时延

C2	**网络辅助测量**	攻击者用网络暴露的 N3/N9/N6、E2E 时延或协作层网络状态**减去网络部分**，得到更纯净的计算时间，提升统计功效	Solution #22.10；KI#5 协作层与 QoS 监测（Solution 变体 #5.9）
C3	**计算指标暴露**	若向 AF 暴露 TTFT、ms/token 或 AIOF 返回"负载→处理时间映射"，且这些指标随某节点缓存状态变化，攻击者无需自测即可读出缓存状态	**Solution #22.9 Variant B；#19.4 Mechanism 2**
C4	**选择结果泄露**	授权后若把"所选 AIOF 地址"返回消费者，而选择算法优先命中节点，则地址/DNAI 变化即泄露命中	§6.19.4.1.1.3（AIOF 信息可提供给消费者）；Solution #22.2 计算节点选择
C5	**计费/用量泄露**	若对命中 token 折价计费，或按请求上报"消耗 token / GPU 用量"，则账单与用量报告泄露命中	计算资源用量（consumed tokens 等）上报；PR 6.14.6-1 按请求计费

关键提醒：标准自身可能"开后门"

C2–C5 是 3GPP 正在讨论的方案在 KV 复用场景下的副作用，学术界的 KV 侧信道研究基本只讨论 C1。**在标准提案中指出这些"放大器"并给出约束条件，是你相对于纯学术方案的差异化价值**，也更容易被 SA2/SA3 接受为"需研究的问题"。

5.3　对附件"6G 放大攻击精度"论点的标准化改写

- "确定性网络微秒级抖动" → 改为："6G 增强的 QoS 监测（包级/PDU Set 级时延测量）与网络状态暴露，使攻击者能更精确地分离网络时延与计算时延"（有条款依据：Solution 变体 #5.9、Solution #22.10、§7.1.5.3）。
- "算力感知路由使路径差异显性化" → 改为："通信-计算协同选择（CCF/CMF/SMF）若以上下文可用性为输入，其选择结果（AIOF 地址、DNAI、UPF 重选）可成为侧信道"（C4）。
- "边缘 MEC 多租户高密度" → 改为："SHE 内多 AF/多第三方模型共享计算资源（6.34 用例），跨租户上下文复用带来隐私风险"（关联 PR 5.5.4.2-2）。

6　基于 3GPP 已有方案的五层防御增强

原则：**3GPP 定义"谁决定、依据什么、下发什么参数、在哪里执行、如何上报"，不定义 KV 数据结构与检测算法**。下文对每一层给出：标准宿主 → 增强设计 → 对原构想的修正。

6.1　L1 分级：从"无感自动"升级为"自动推荐 + 声明 + 运营商策略裁决"

标准宿主	增强设计
UDM 签约数据（允许的 AI 服务类型）	新增签约属性 `AllowedContextReuseScope`：{None | Session | User | Tenant | Global}，作为上限
PCF 策略（AI 资源使用、AI 模型/AIOF 选择、AI 服务优先级等运营商策略）	新增 `Context Reuse Policy`：按 AF/应用/模型下发默认等级、L0 白名单、提升/降级规则
AI 推理服务请求参数（AF/UE 可提供详细信息）	请求中可携带 `Requested Sensitivity`（AF 对自身系统提示/RAG 文档的声明）
AI 推理会话上下文（IE 为 FFS）	AIMF 写入最终裁决的 `Context Sensitivity Level` 与 `Reuse Domain ID`
数据框架"按元数据治理复用、可限制复用方"原则（§7.1.21.8）	借用其思想：每个可复用上下文附带元数据（等级、所属域、保留期），复用前必须匹配

默认私有（private-by-default）：新生成的 KV 块先按"会话/租户内私有"入库，由 AIOF 侧的自动分级（你的"租户熵"算法）在后台评估，**只有在策略允许且达到阈值时才提升为 L0**；任何可疑访问立即降级。这与 SafeKV 的做法一致，可避免误分类直接导致泄露。

6.2　L2 盲化：重新定位为"按复用域分盐的命名空间隔离"

- **标准宿主**：AIMF 授权 + 签约绑定的凭证。TR 23.801-01 的 UE AI Agent 方案中已出现"任务范围 ID 通过 AKMA 派生密钥绑定签约"的思路；TR 33.801-01 KI#8.2 临时结论要求"AI Agent 授权须与签约凭证绑定"。
- **增强设计**：上下文索引键 = `H(K_domain ‖ model_id ‖ token_prefix)`，其中 `K_domain` 由 AIMF 依据 `Reuse Domain ID` 派生并下发给 AIOF/AISF；L0 域使用公共/全网密钥，L1–L3 使用租户或用户密钥。攻击者不在同一域，则**即便构造出完全相同的前缀也查不到**对方的块。
- **密钥生命周期**：签约撤销/订户许可撤回 → 域密钥轮换 → 旧块不可寻址并被回收（呼应数据框架"许可撤回则删除相关数据"的原则）。
- **对原构想的修正**：雪崩效应本身**不是**防护来源（详见 §9.4）；"语义哈希"若用于跨租户匹配，反而会扩大可探测面，应只用于 L0。

6.3　L3 时序对齐：用 QoS 参数表达"释放时刻"，并收紧指标暴露

- **标准宿主**：KPI 机制 1 中 AIMF 推导的"首个下行推理结果的最大传输时延"；KI#5 已同意"QoS 可随应用需求变化（在授权范围内）"；xUPF 的"业务特定功能"。
- **增强设计 A（释放时刻量化）**：AIMF 为 L0/L1 会话下发 `Target First-Result Latency` 与 `Release Quantum`（如 50 ms 粒度），AIOF（或 AISF/xUPF 作为业务特定功能）将首结果的释放时刻对齐到量化桶，**使"本地命中 / 远端命中 / 同站热迁移"不可区分**。
- **增强设计 B（指标暴露约束）**：对启用跨租户复用的 Computing Site，**只允许 Solution #22.9 Variant A/E、#22.15 的抽象化暴露**；Variant B 的 TTFT、ms/token 需满足"聚合窗口 ≥ T、按服务等级而非单节点、限频"；#19.4 Mechanism 2 的"负载→时间映射"只能基于**与缓存状态无关的计算模型**（例如按"未命中"保守估计）生成。
- **增强设计 C（选择结果不外露）**：L1+ 会话对消费者只暴露 AISF 锚点地址，不暴露具体 AIOF；AIOF 切换在 AISF 后面完成（C4 防护）。
- **增强设计 D（计费去相关）**：对外计费按"逻辑 token"统一计价，命中节省的成本只在运营商内部核算；对外用量报告按时间窗聚合（C5 防护）。
- **对原构想的修正**：L3 只能消除"命中层级差异"，**不能消除命中/未命中差**；L1+ 私有内容的安全依赖 L2 域隔离，而非 L3（§9.5）。

6.4　L4 探测检测与响应：从"蜜罐假数据"改为"隔离 + 诱饵前缀"

- **标准宿主**：TR 33.801-01 KI#7.2（检测使用合法凭证的攻击、跨 NF 关联）与 KI#7.3（响应框架可"重定向检测到的恶意流量、异常行为和可疑 API 调用"）；TR 22.870 PR 5.5.4.2-4~6；AIMF 资源重绑定；身份可归属到 SUPI/GPSI。
- **增强设计**：
  1. AIOF/AISF 上报"安全相关数据"：每域的前缀树深节点分叉速率、复用多样性比（RDR）、同一前缀被不同 SUPI 触达的分布等（不含提示明文）。
  2. 安全监测功能（3GPP 外）关联多 NF 数据，识别 A3 类分布式探测——**这是 6G 相对公有云 API 的结构性优势：每个请求都绑定可归属的签约身份**，"注册无数免费账号"的成本远高于云 API。
  3. 响应动作（经 KI#7.3 下发）：AIMF 将可疑会话**重绑定到"无跨租户复用"的隔离 AIOF**（结果真实、性能略降），并在其可见缓存中只放置**诱饵前缀（canary）**；若诱饵被"命中探测"，即获得高置信攻击证据，再按运营商策略升级处置（限速、撤销授权、通知 AF）。
- **对原构想的修正**：不向已认证用户返回伪造推理结果（§9.6）。

6.5　L5 不可观测化执行：以策略标识触发，具体实现留在 SHE

- **标准宿主**：签约/策略中的 AI 服务类型与优先级；PR 5.5.4.2-2 细粒度安全隔离；Solution #22.15 只报告抽象的"策略符合状态"。

- **增强设计**：定义策略标识 `Constant-Latency Execution Required`，AIMF 选择具备该能力的 AIOF（AIOF 注册其能力，类似 §6.19.4 原则 4 的能力登记）；执行方式（影子计算、TEE、固定批次填充）属实现。计费按完整计算计价。
- **对原构想的修正**：L3 请求本就禁止跨租户复用，影子计算主要用于防范**租户内/会话内**剩余信道及平台级观测，比例假设（<1%）需由运营商策略决定。

6.6 五层之外：3GPP 场景下必须补齐的四项

补充项	理由与设计
上下文完整性（防投毒）	NDSS 2026 文献讨论了通过毒化前缀缓存/语义缓存破坏 LLM 输出的威胁 [NDSS 2026]。L0 共享块须由生成 AIOF 签名/带完整性标签，迁移链路需机密性、完整性与重放保护（对齐 TR 33.801-01 对接口安全的通用要求）
迁移安全	KI#22 的上下文迁移链路（直连或经 UPF）应只在同一复用域内建立；跨域迁移须重新加密/重新派生
合法监听与数据留存	TR 23.801-01 §4.2 要求考虑 TS 33.126。KV 块是用户内容的派生物，需明确：它不是通信内容的替代副本，且在会话/许可结束后按策略删除
漫游与跨运营商	首期限定 PLMN 内；漫游场景沿用计算漫游 HR-SBO 基线，复用域不跨 PLMN，除非有运营商间协议

7 建议的整体架构与关键流程

7.1 功能架构

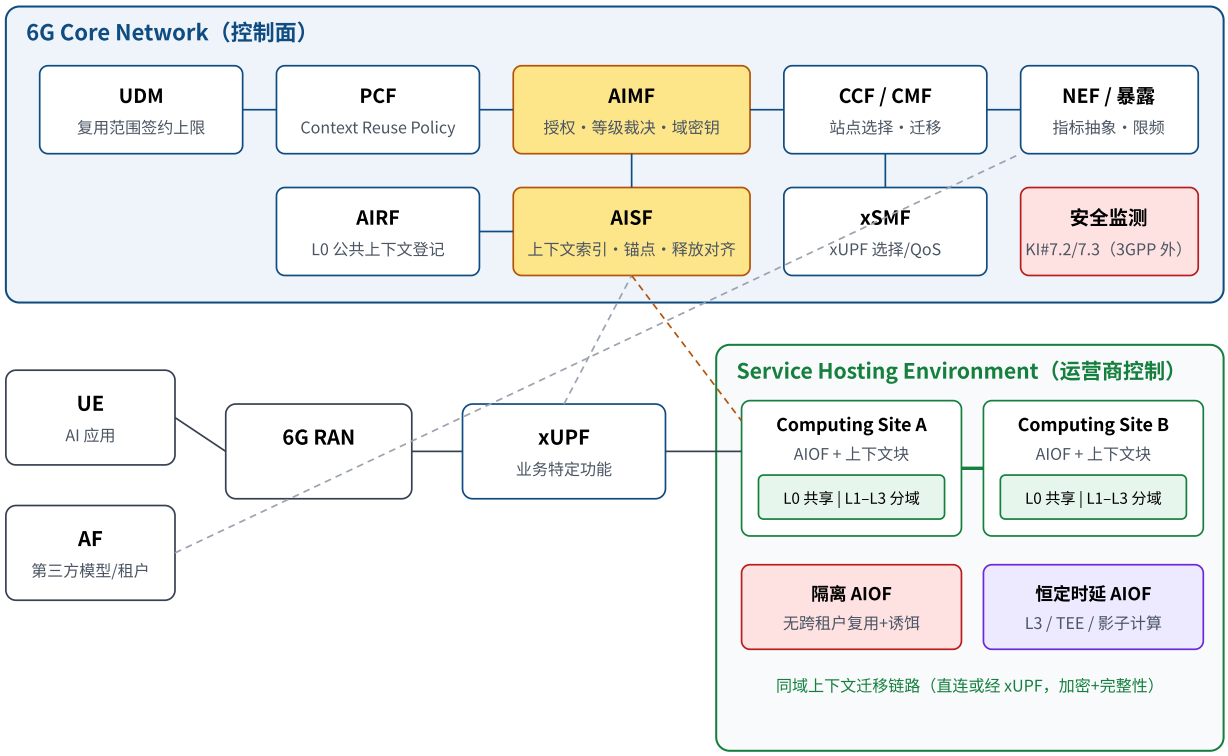


图 7-1 建议的"可复用 AI 推理上下文"功能架构（实线：用户面；虚线：控制/管理关系；黄色为主要增强网元）

7.2 流程一：带复用范围的推理服务建立

1. UE（经 NAS/UP）或 AF（经 NEF）发起 AI 推理服务请求，携带模型 ID、KPI（E2E 时延、精度）、可选 `Requested Sensitivity`。
2. AIMF 从 UDM 取签约（`AllowedContextReuseScope`），从 PCF 取 `Context Reuse Policy`，裁决 `Context Sensitivity Level` 与 `Reuse Domain ID`，派生域密钥。
3. AIMF 与 CCF/CMF 协同选择 AISF 与候选 AIOF：**上下文可用性只作为选择的"软输入"，且对 L1+ 会话不对外暴露选择结果**。
4. AIMF 生成 AI 推理会话上下文（含新 IE），向 AISF/AIOF 下发：域密钥、`Target First-Result Latency`、`Release Quantum`、是否 `Constant-Latency Execution Required`。
5. AIMF 推导 QoS 要求并经 xSMF/PCF 建立 QoS Flow；向消费者返回 AISF 锚点地址。

7.3 流程二：请求执行与释放对齐

1. 请求经 xUPF 到达 AISF；AISF 用 `H(K_domain || model_id || prefix)` 查询索引（L0 先查公共域，再查本域）。

2. 本地命中→直接执行；远端命中→从同域节点拉取（迁移链路）；未命中→完整 prefill。
3. AIOF/AISF 将首个结果的释放时刻对齐到量化桶（L0/L1）；L3 走恒定时延 AIOF。
4. 新生成块默认私有入库；后台分级达到阈值且策略允许时提升为 L0，并在 AIRF 登记。

7.4 流程三：探测检测与重绑定

1. AIOF/AISF 周期性上报每域的复用统计与异常特征（不含明文）至安全监测功能。
2. 安全监测关联多站点、多 SUPI 数据，识别可疑会话；经响应框架通知 AIMF。
3. AIMF 触发资源重绑定：可疑会话迁至隔离 AIOF（真实结果、无跨租户复用、诱饵前缀）。
4. 诱饵被探测命中 → 证据确认 → 按策略限速/撤销授权/通知 AF；相关 L0 块按需降级或轮换域密钥。

7.5 建议新增的信息元素（IE）一览

IE	载体	含义
`AllowedContextReuseScope`	UDM 签约	该用户/应用可被允许的最大复用范围
`Context Reuse Policy`	PCF→AIMF	默认等级、L0 白名单、提升/降级规则、保留期
`Requested Sensitivity`	AI 推理请求	UE/AF 对其上下文敏感度的声明
`Context Sensitivity Level` / `Reuse Domain ID`	AI 推理会话上下文	AIMF 最终裁决
`Target First-Result Latency` / `Release Quantum`	AIMF→AIOF/AISF（及 QoS）	释放时刻对齐参数
`Constant-Latency Execution Required`	策略 / AIOF 能力登记	触发 L5 执行模式
`Context Reuse Security Report`	AIOF/AISF→安全监测	复用统计与异常特征（KI#7.2 安全相关数据）

8 标准化切入路径与时间窗口

工作组	目标条款	建议提交内容
SA2	TR 23.801-01 §6.19.4（方案变体 #19.4）/ §7.1.19.2	①在 AISF/AIMF/AIOF 功能划分（FFS）中写明"可复用推理上下文的索引、授权与复用范围控制"；②补充 AI 推理会话上下文的 IE（FFS 项）；③在 KPI 机制中加入"首结果释放对齐"作为可选机制；④对 Mechanism 2 的映射信息增加"不得反映上下文缓存状态"的 NOTE
SA2	§6.22（KI#22）/ §7.1.22.1	把"有状态计算上下文迁移"扩展为"同复用域内的 AI 推理上下文迁移"；对 Solution #22.9 Variant B 加入 TTFT/ms-token 暴露约束；选择结果不外露原则
SA2	KI#5 / KI#7	对时延类监测与暴露增加"粒度/聚合/限频"可配置项（运营商可控）
SA3	TR 33.801-01（新 Key Issue）	**建议新增 KI："Security and privacy of network AI inference service"**，威胁写入"跨消费者推理上下文复用引入的时序侧信道"及 C2–C5；潜在需求："6G 系统应支持防止通过推理服务时延、暴露指标、选择结果或计费信息推断其他消费者的推理输入"
SA3	KI#7.2 / KI#7.3	把"推理上下文复用异常"列入新的安全相关事件；把"重绑定至隔离推理实例"列入响应动作
SA1	Rel-21 Stage-1（TS 22.x 系列，Stage-1 冻结 2027-03）	以 PR 5.5.4.2-2 与 PR 5.5.7.3-2 为依据，争取一条明确需求："在提供 AI 推理服务时，6G 系统应在保障性能的同时防止跨用户的推理输入泄露"
SA5	计费 / OAM	计算资源用量与计费的聚合粒度；复用策略的 OAM 配置

时间建议

- **2026 Q4 – 2027 Q1**：TR 23.801-01 仍在增补方案与临时结论，KI#19/KI#22 的架构收敛是 FFS——优先提交 SA2 方案增强与 SA3 新 KI。
- **2027 Q1**：Rel-21 Stage-1 冻结前完成 SA1 需求对齐。
- **2027 – 2028 Q2**：Rel-21 Stage-2 规范阶段（冻结 2028-06）——转为 TS 级 CR，聚焦 IE、流程与 NOTE。

专利撰写建议：权利要求宜落在**系统级信令与网元行为**（AIMF 基于签约与策略裁决复用域并派生域密钥；AISF 对外隐藏 AIOF 选择；释放时刻量化参数的下发与执行；基于安全监测的重绑定至隔离实例），这些是标准可能采纳、可被检测到的特征；Radix Tree 与哈希细节适合作为从属权利要求或实施例。

9　构想中不合适 / 需修正之处（独立章节）

本章逐条列出附件构想与 6G 标准原则、3GPP 范围或安全逻辑不一致的地方，并给出修正建议。严重 表示原样提交可能被否决或存在安全漏洞；中等 表示需改写表述或补充约束；轻微 表示措辞或证据问题。

9.1　"KV Cache"本身不是 3GPP 对象 严重

问题：TR 23.801-01 明确推理结果的详细参数是"应用层载荷、3GPP 不定义"；§7.1.22.1 规定 SA2 不规定应用组件的打包、存储、实例化与生命周期管理；§4.2 要求多厂商互通。前缀树、哈希、影子计算都属于实现。

修正：提案以"可复用 AI 推理上下文"为抽象对象，只标准化*复用范围的授权与裁决*、*参数下发*、*选择与暴露约束*、*安全数据上报与响应*；KV 结构作为 NOTE 示例。

9.2　"类 CDN 的广域共享"与 SHE"运营商完全控制"的边界 严重

问题：临时结论将计算托管限定在运营商控制的 SHE 内，应用流量只经 6G UPF 进入；数据框架消费者接口为非漫游；计算漫游仅以 HR-SBO 为基线。跨运营商、跨第三方云的"全网 CDN"超出当前标准范围，也带来跨信任域的密钥与合规问题。

修正：首期范围限定为"单 PLMN 内多个 SHE 计算站点之间"；跨 PLMN 作为后续增强（依赖运营商间协议与漫游架构结论）。

9.3　不宜借用数据框架存储 KV 中等

问题：KI#21 数据框架面向"6G 系统数据"（网络数据、UE 数据采集、分析），数据存储功能"不独立发起数据收集"、实际存储技术在 3GPP 外。KV 是用户推理输入的派生物、体量大、时延敏感，放进数据框架会与其定位冲突，也会触发大量订户许可/匿名化流程。

修正：KV 存储在 AIOF/AISF（KI#19），只借用数据框架的"元数据治理复用范围"思想。

9.4　"雪崩哈希破坏映射梯度"的安全逻辑不成立 严重

问题：前缀探测攻击并不依赖"梯度"。攻击者每次提交的是*完整的候选前缀*（已恢复部分 + 下一个候选 token），只要其请求与受害者落在同一查找空间，完全相同的前缀就会得到相同的哈希/盐，命中照样发生。SHA-256 的雪崩效应只保证"不同输入的哈希无关"，并不阻止"相同输入的精确匹配"。若盐对所有租户相同或可推导，盲化等于没有盲化。

修正：防护来源应定义为**按复用域分配的秘密密钥（K_domain）带来的命名空间隔离**（§6.2）。"语义哈希"只用于 L0 公共域，因为语义近似匹配会扩大可探测面（攻击者用近义改写也能触发命中）。

9.5　L3 对齐到 ~100 ms 无法隐藏"命中 vs 未命中" 严重

问题：附件把命中时延对齐到"跨节点拉取时间"（~100 ms），这只抹平"本地命中 vs 远端命中"；未命中仍需 5000 ms 级重算，两者相差约 50 倍，单次测量即可区分。若私有内容进入全局可查空间，L3 不能提供保护。另外，此前提与附件"抹平边缘节点缓存状态差异"的表述一致，但与"攻击彻底失效"的结论不一致。

修正：明确 L3 的保护目标是"隐藏位置/层级信息与站点负载信息"；对 L1–L3 的保护依赖 L2 域隔离；跨域不可能命中，自然无需对齐到重算时间。

9.6　"静默路由到蜜罐并让攻击者收集伪造数据" 严重

问题：① 3GPP 强调对 AI 推理服务保障 KPI（含精度，原则 29、PR 6.10.6-3），并在 TR 22.870 6.39 中讨论负责任/可信 AI——网络有意返回错误推理结果与此冲突；② 检测必然有误报，被误判的合法用户（如做 A/B 测试、批量改写提示的开发者）将收到错误结果，可能引发安全事故与法律责任；③ 合法监听与监管场景下，网络篡改用户可见内容难以辩护；④ 3GPP 的响应框架允许"重定向"，但没有"欺骗"语义。

修正：改为"重绑定至**无跨租户复用的隔离实例**（结果真实，仅失去共享收益）+ 在其可见缓存中放置**诱饵前缀**"，以诱饵命中作为高置信证据，再按策略处置。这样同样"静默"、同样让攻击者一无所获，但不伤害误判用户。

9.7　"100% 自动、无需用户打标签"与运营商可控 / 订户许可原则 中等

问题：KI#18 临时结论要求运营商可控；KI#7、KI#21 强调基于运营商策略/SLA、隐私保护与订户许可；"租户熵"高并不代表内容可公开（例如多个租户都在用同一份泄露的机密文档或同一类病历模板）。纯自动分级既不可审计，也可能被攻击者通过"制造共享度"来诱导提升等级（投毒式提升）。

修正：自动分级作为推荐；最终等级由 AIMF 依据签约上限、PCF 策略、AF 声明裁决；默认私有；提升需满足"不同签约主体数 ≥ N 且来源多样性"等抗操纵条件。

9.8　标准自身的泄露面未纳入构想 中等

问题：附件只考虑 TTFT 主信道，未考虑 6G 方案中的计算指标暴露（Solution #22.9 Variant B 的 TTFT/ms-token）、Mechanism 2 的处理时间映射、AIOF 地址回传、按 token 计费。即使五层全部实现，这些旁路也可能泄露命中状态。

修正：增加"暴露与计费去相关"子层（§6.3 设计 B/C/D），这也是对 3GPP 最有说服力的增量。

9.9　"6G 确定性网络微秒级抖动"的表述缺乏 SA2 依据 轻微

问题：TR 23.801-01 中没有把"微秒级确定性"作为通用 6G 特性；TR 22.870 中的确定性低时延需求针对特定业务（如 PR 9.18.6-1、PR 9.3.6-4）。在标准提案中使用这一说法容易被质疑。

修正：改为"增强的 QoS 监测与网络状态暴露提高了攻击者的测量精度"（§5.3）。

9.10　定量指标缺乏可复核依据 中等

问题："复用率 ≥95%""TTFT 增加 ≤5%""30 天内 >80% 置信度不可区分"均无测量方法与负载定义。文献数据显示：按用户隔离使 TTFT 增加 2.3%–38.9%（视模型与重叠度而定），选择性共享可显著回收但不为零 [SafeKV]。L0 复用率高度依赖业务的跨租户前缀重叠度，本身可能远低于 95%。

修正：定义评估方法：工作负载（跨租户重叠度分布）、攻击者模型（A1–A3、查询预算）、统计检验（如 KS 检验、区分优势 Advantage）、指标（"复用率"应定义为 L0 可复用 token 占比，而非全体）；在提案中以"示例/目标值"表述而非承诺值。

9.11　"<1% 绝密请求"等比例假设与"彻底""完美"等措辞 轻微

问题：3GPP 文档避免绝对化表述，比例应由运营商策略决定；侧信道防护只能将泄露"界定在可度量范围内"。

修正：用"mitigate""bound the leakage""subject to operator policy"等措辞。

9.12　未覆盖投毒、迁移安全、合法监听与数据留存 中等

问题：共享 KV 天然面临完整性威胁（毒化公共前缀改变他人输出）；KI#22 的上下文迁移链路需要安全保护；TR 23.801-01 §4.2 要求考虑合法监听；订户许可撤回后派生数据需删除。

修正：按 §6.6 补齐。

9.13　汇总

#	不合适之处	严重度	一句话修正
1	KV Cache 不是 3GPP 对象	严重	抽象为"可复用 AI 推理上下文"，只标准化信令与策略
2	跨运营商广域 CDN 超出 SHE 边界	严重	首期限定单 PLMN 多 SHE
3	借用数据框架存 KV	中等	存于 AIOF/AISF，仅借元数据治理思想
4	雪崩哈希防探测	严重	改为按域秘密密钥的命名空间隔离
5	对齐到 100 ms 隐藏命中	严重	L3 只隐藏层级；私有内容靠域隔离
6	蜜罐返回伪造数据	严重	隔离实例 + 诱饵前缀
7	100% 自动分级	中等	自动推荐 + 声明 + 运营商裁决，默认私有
8	忽略标准自身泄露面	中等	增加暴露/选择/计费去相关
9	"确定性网络微秒抖动"	轻微	改为 QoS 监测与暴露提升测量精度
10	定量指标无依据	中等	给出评估方法，指标作目标值

11	比例假设与绝对化措辞	轻微	由策略决定；用 mitigate/bound
12	缺投毒/迁移/LI/留存	中等	按 §6.6 补齐

10 结论与下一步

10.1 结论

1. **方向正确、时机合适**：6G 正在把"网络提供 AI 推理"写进架构（KI#19 第 4 条已有临时结论），而推理上下文复用及其侧信道在 SA2/SA3 均属空白。
2. **最佳挂点**：AISF 的"AI context caching management"+ AI 推理会话上下文的 FFS IE + KI#22 有状态上下文迁移。
3. **最大增值**：指出并约束 6G 方案自身的泄露放大器（计算指标暴露、处理时间映射、选择结果回传、按 token 计费），这是纯学术方案没有的视角。
4. **必须修正**：L2 的安全来源（域密钥隔离而非雪崩）、L3 的保护边界（层级而非命中）、L4 的反制方式（隔离 + 诱饵而非伪造数据）。

10.2 建议的下一步

#	行动	产出
1	按第 9 章修订附件方案，尤其是 L2/L3/L4 的定义	修订版技术交底书
2	搭建评估：多租户工作负载 + A1–A3 攻击者 + 统计检验，测 L0 复用率与 TTFT 开销	可复核的定量数据
3	起草 SA2 pCR：在 TR 23.801-01 §6.19.4 中增补上下文复用控制与 IE、Mechanism 2 的 NOTE	SA2 提案
4	起草 SA3 新 KI："Security and privacy of network AI inference service"	SA3 提案
5	专利布局：以系统级信令与网元行为为主权项	权利要求草案

附录　参考资料与条款索引

A.1　3GPP 文档

- 3GPP TR 23.801-01 V0.10.0（2026-10），Study on Architecture for 6G System; Stage 2（Release 20）——23801-01-0a0.zip；归档目录：23.801-01 archive
- 3GPP TR 33.801-01 V0.7.0（2026-10），Study on Security for the 6G System（Release 20）——33801-01-070.zip
- 3GPP TR 22.870 V20.0.0（2026-03），Study on 6G Use Cases and Service Requirements; Stage 1（Release 20）——22870-k00.zip
- 3GPP Release 21 时间表——Release 21；Release 20——Release 20

A.2　学术文献

- G. Wu et al., "I Know What You Asked: Prompt Leakage via KV-Cache Sharing in Multi-Tenant LLM Serving," NDSS 2025——PDF
- K. Chu et al., "Selective KV-Cache Sharing to Mitigate Timing Side-Channels in LLM Inference"（SafeKV）——arXiv 2508.08438
- "Mitigating Prefix Caching Side Channels in Shared LLM Serving"——arXiv 2603.10726
- X. F. Wu et al., "Cache Related Security Threats in LLM Serving Frameworks," NDSS 2026——PDF

A.3　条款索引（本报告引用）

条款	内容
TR 23.801-01 § 4.1 / § 4.2	架构假设；架构需求（漫游、多厂商互通、LI、安全需求）
§ 5.19 KI#19 第 4、5 条	6G CN 提供 AI 推理/训练服务；AI 流量特性（§ 6.19.5 待补）
§ 6.19.4.0 / 6.19.4.1.1	原则 1–29；AIMF/AIOF/AIRF/AISF；架构选项 1–4；授权；登记与发现
§ 6.19.4.1.3	AI 推理会话上下文；调用参数；执行路径；KPI 保障机制 1–6；服务连续性与资源重绑定
§ 6.22.2 / 6.22.9 / 6.22.10 / 6.22.15	通信-计算协同；计算服务连续性与上下文迁移；计算信息暴露（含 TTFT、ms/token）；网络指标暴露；SHE 抽象状态
§ 6.4.10	增值业务用户面（VAS-UP）
§ 6.5.9	QoS 监测增强
§ 6.21.12	数据隐私与订户许可执行

§7.1.4 / 7.1.5 / 7.1.7 / 7.1.18 / 7.1.19 / 7.1.21 / 7.1.22	各 KI 临时结论
TR 33.801-01 §4.1；§5.6（KI#6.1–6.4）；§5.7（KI#7.1–7.3）；§5.8（KI#8.1–8.2）；§5.9（KI#9.1–9.2）	安全区划分；暴露安全；安全监测与响应；UE AI Agent 安全；数据框架安全
TR 22.870 §5.5.4、5.5.7、5.9.2、6.2、6.10、6.13、6.24、6.34、6.39	安全隔离、隐私、数据全生命周期、计算任务迁移、AI 推理服务、RAG、分布式 AI 计算、推理卸载、负责任 AI

检索说明：本报告对三份 TR 全文进行关键词检索，"KV cache / key-value cache / prefix cach / side channel / timing attack"在三份文档中均无匹配（TR 33.801-01 中 "timing" 仅出现在与本主题无关的上下文）。标准内容均为研究阶段草案，可能在后续会议中修改。